Tópicos selecionados de programação em

Gerência de Memória em Java Parte I: Arquitetura da JVM e algoritmos de coleta de lixo



Por que gerenciar memória?

- Há linguagens em que a alocação de memória é trivial, e não requerem gerenciamento complexo
- Estratégias de alocação de memória
 - Estática: áreas de memória são alocadas antes do início do programa; não permite mudanças nas estruturas de dados em tempo de execução (ex: Fortran)
 - Linear: memória alocada em fila ou em pilha; não permite remoção de objetos fora da ordem de criação (ex: Forth)
 - Dinâmica: permite liberdade de criação e remoção em ordem arbitrária; requer gerência complexa do espaço ocupado e identificação dos espaços livres (ex: Java, C++)
- Java utiliza alocação dinâmica (heap) para objetos e alocação linear (pilha) para procedimentos seqüenciais
 - Mas todo o gerenciamento é feito automaticamente



Gerencia de memória? Em Java?

- Então, por que se preocupar com memória em Java?
 - Diferentemente de C ou C++, programadores Java não têm a responsabilidade e nem a possibilidade de gerenciar a memória do sistema explicitamente
 - Programação em alto-nível: alocação e liberação de memória dinâmica é realizada automaticamente usando algoritmos: programador preocupa-se apenas com a lógica do programa
- Mas algoritmos são configurados para situações típicas
 - Determinadas aplicações podem requerer ajustes (tuning):
 performance, escalabilidade, segurança, throughput vs. liveness
 - Saber o quanto, quando, onde ajustar requer conhecimentos elementares da organização da memória e dos algoritmos de coleta de lixo empregados pela implementação da JVM usada



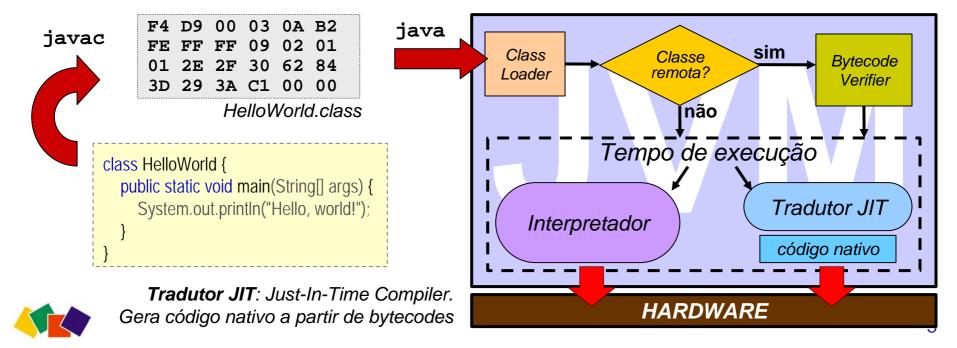
Assuntos abordados

- Este minicurso explora detalhes sobre o uso de memória virtual em aplicações Java
- Está dividido em três partes
 - Parte I: este módulo (arquitetura da JVM, alocação de memória e algoritmos de coleta de lixo)
 - Parte II: arquitetura da HotSpot JVM e estratégias de ajuste e otimização de performance
 - Parte III: finalização, controle do coletor de lixo, memory leaks e objetos de referência
- Tópicos deste módulo (primeira parte)
 - 1. Anatomia da JVM
 - 2. Coleta de lixo: algoritmos elementares
 - 3. Coleta de lixo: algoritmos combinados (estratégias)
 - 4. Coleta de lixo em paralelo (coletores não-seriais)



1. Anatomia da JVM

- A máquina virtual Java (JVM) é uma máquina imaginária implementada como uma aplicação de software [JVMS]
 - Ela executa um código de máquina portável (chamado de Java bytecode) armazenado em um formato class
 - O formato class geralmente é gerado como resultado de uma compilação de código-fonte Java



Java esconde detalhes da memória

- A especificação da máquina virtual (Java Virtual Machine Specification [JVMS]) não determina:
 - Detalhes de segmentação da memória (como ocorre o uso de memória virtual, onde fica a pilha, o heap, etc.)
 - O algoritmo de coleta de lixo usado para liberar memória (diz apenas que deve haver um)
 - Outros aspectos de baixo nível como formato de tipos, etc.
- Diferentes implementações da JVM têm a liberdade de organizar a memória diferentemente e escolher algoritmos de coleta de lixo diferentes
 - Sun HotSpot JVM (mais popular; a da IBM é similar)
 - Jikes RVM (experimental; popular entre cientistas)



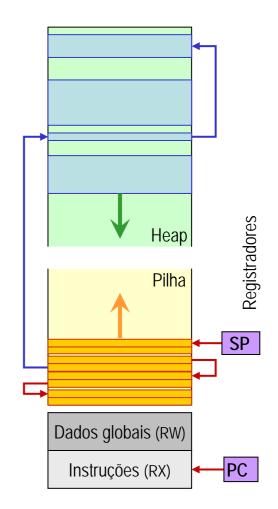
A pilha, o heap e a JVM

- Do ponto de vista de um programador Java, as áreas de memória virtual conhecidas como a pilha e o heap são lugares imaginários na memória de um computador
 - Não interessa nem adianta saber onde estão
 - Java não oferece opções de escolha: "tipos primitivos ficam na pilha e objetos ficam no heap e ponto final!"
- Implementações da especificação da JVM, (como a HotSpot JVM), oferecem parâmetros que permitem algum controle sobre a gerência de memória
 - Conhecer as escolhas de algoritmos e arquitetura da máquina virtual usada é importante para saber como configurá-la e quais parâmetros ajustar para obter melhor performance
 - Ainda assim, o controle é limitado e não existe, em Java, a disciplina "gerência de memória" como existe em C ou C++



Segmentação de memória virtual: esquema lógico de baixo nível

- O diagrama ao lado é apenas um modelo genérico* e não reflete nenhuma implementação real
 - Os blocos azuis no heap indicam memória alocada dinamicamente
 - Os blocos amarelos na pilha podem indicar frames (seqüências de instruções de cada método) de um único thread
 - As setas azuis indicam ponteiros



PC = Program counter

SP = Stack pointer

^{*} Modelo inspirado em segmentação C/C++. A especificação da JVM descreve a memória em nível mais alto (ex: não sugere onde o heap ou pilha devem ser localizados, não descreve organização do heap, permite pilha não contígua, etc.)

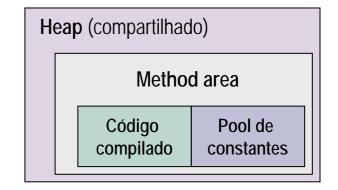
Anatomia da JVM: áreas de dados

 A máquina virtual define várias áreas de dados que podem ser usadas durante a execução de um programa

Registrador PC

(um por thread)

- Pilhas e segmentos de pilha (quadros)
- Heaps e área de métodos
- Registradores
- Algumas áreas estão associadas a threads (privativas)
 - São criadas/alocadas quando um thread novo é criado
 - São destruídas/liberadas quando o thread termina
- Outras áreas estão ligadas à máquina virtual (compartilhadas)
 - Criadas quando a JVM é iniciada
 - Destruídas quando a JVM termina



Pilhas (uma para cada thread)





O registrador PC

- Cada thread de execução tem um registrador PC (program counter)
- Em qualquer momento, cada thread estará executando o código de um único método
 - Um método (Java ou bytecode) consiste de uma lista de instruções executadas em uma seqüência definida
- O registrador PC contém o endereço da instrução da JVM que está sendo executada
 - O valor do registrador PC só não é definido se o método for um método nativo (implementado em linguagem de máquina da plataforma onde roda)



Pilhas da JVM

- Cada thread é criado com uma pilha associada
 - É usada para guardar variáveis locais e resultados parciais
- A memória usada pela pilha
 - Pode ser alocada no heap
 - Não precisa ser contígua
 - É liberada automaticamente depois de usada
 - Pode ter um tamanho fixo ou expandir-se e contrair-se na medida em que for necessário (implementações de JVM podem oferecer controles para ajustar tamanho de pilhas)
- Quando a memória acaba, dois erros podem ocorrer
 - StackOverflowError: se a computação de um thread precisar de uma pilha maior que a permitida (métodos que criam muitas variáveis locais, funções recursivas)
 - OutOfMemoryError: se não houver memória suficiente para expandir uma pilha que pode crescer dinamicamente.



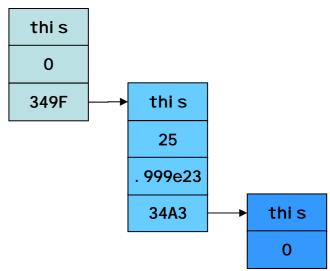


Quadros de pilha (frames)

- Um quadro (frame) é um segmento alocado a partir da pilha de um thread, sempre que um método é chamado
 - É criado cada vez que um método é chamado (todo método tem um quadro associado)
 - É destruído quando a chamada termina (normalmente ou não)
 - É sempre local ao thread (outros threads não têm acesso a ele)

É usado para

- guardar resultados parciais e dados
- realizar ligação dinâmica
- retornar valores de métodos
- despachar exceções
- Cada quadro possui
 - Um array de variáveis locais
 - Uma pilha de operandos
 - Referência ao pool de constantes de runtime da classe corrente.



Quadros correntes e chamadas

• Em um determinado thread, apenas um quadro está

ativo em um determinado momento

- Chama-se quadro corrente
- Seu método é o método corrente
- Sua classe é a classe corrente
- Quando o método corrente m1, associado ao quadro q1, chama outro método m2
 - Um novo quadro q2 é criado (que passa a ser o quadro corrente)
 - Quando o método m2 retornar, o quadro q2 retorna o resultado da sua chamada (se houver) ao quadro q1

thi s m2() 0 thi s 349F m1() . 7e2 thi s m2() 0 thi s 490.0 1234 . 7e2 m1()

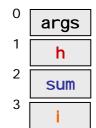
O quadro q2 é descartado e q1 volta a ser o quadro corrente



Variáveis locais

- Cada frame possui um vetor de variáveis contendo as variáveis locais do seu método associado.
 - Variáveis de até 32 bits ocupam um lugar no array
 - Variáveis de 64 bits ocupam dois lugares consecutivos
- São usadas para passar parâmetros durante a chamada de métodos
- Variáveis locais são acessadas pelo seu índice (a partir de 0)
 - Em métodos estáticos, a variável local
 de índice 0 é o primeiro parâmetro passado ao método
 - Em métodos de instância, a variável local de índice 0 sempre contém a referência this; os parâmetros são passados a partir da variável local de índice 1

Variáveis locais de método estático



thi s

soma(x,y)

locais de

método de instância

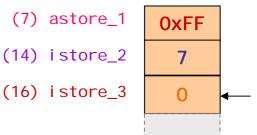
```
main(args) {
Hello h=...
int sum=...
for(int i=
```



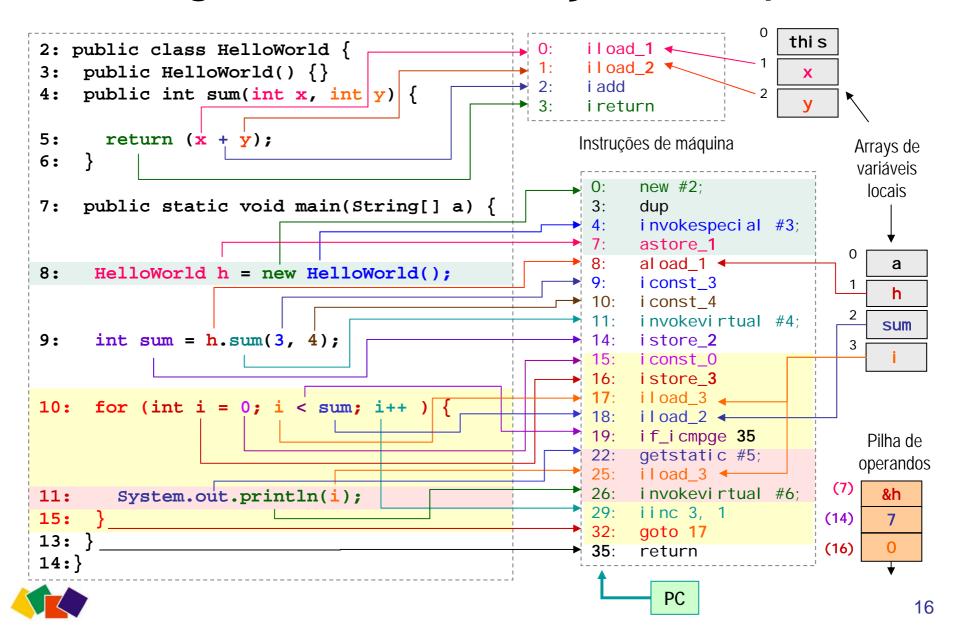
Pilha de operandos

- Cada quadro contém uma pilha LIFO conhecida como Pilha de Operandos
 - Quando o quadro é criado, a pilha é vazia
 - Instruções da máquina virtual carregam
 constantes ou valores de variáveis locais ou
 campos de dados para a pilha de operandos, e vice-versa
 - A pilha de operandos também serve para preparar parâmetros a serem passados a métodos e para receber seus resultados
- Qualquer tipo primitivo pode ser armazenado e lido da pilha de operandos.
 - Tipos long e double ocupam duas unidades da pilha.
- Operações sobre a pilha de operandos respeitam os tipos dos dados guardados



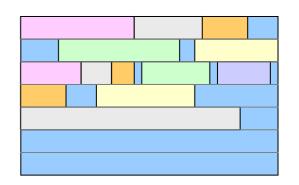


Código Java e instruções de pilha



O heap

- O heap é a área de dados onde todas as instâncias e vetores são alocados
 - Compartilhada por todos os threads
 - Criada quando a máquina virtual é iniciada
 - Não precisa ser uma área contígua



- O espaço de objetos no heap é reciclado por um sistema de gerenciamento de memória (coletor de lixo)
 - Algoritmo depende da implementação da JVM
- Pode ter tamanho fixo ou ser expandido/contraído
 - Implementações podem oferecer controles para ajustar tamanho do mínimo/máximo ou fixo do heap
- Se um programa precisar de mais heap que o que foi disponibilizado, a JVM causará OutOfMemoryError.



Área de métodos

- Parte do heap usada para guardar código compilado de métodos e construtores
 - Criada quando a máquina virtual inicia
 - Geralmente armazenada em uma área de alocação permanente (a especificação não determina a localização)
 - Compartilhada por todos os threads
- Guarda estruturas compartilhadas por todos os métodos de uma classe como
 - Pool de constantes de runtime (constantes de diversos tipos usados pelo método)
 - Dados usados em campos e métodos
- OutOfMemoryError ocorre se em algum momento não houver mais espaço para armazenar código de métodos





Ferramenta javap

- Para obter informações sobre a estrutura de uma classe e instruções da JVM usadas use javap -c Classe
- A ferramenta javap permite visualizar o conteúdo de um arquivo de classe

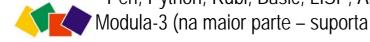
```
javap [-opções] classe
```

- Usando opções -c e -verbose é possível ver
 - Seqüência de instruções da JVM
 - Tamanho dos quadros de cada método
 - Conteúdo dos quadros
 - Pool de constantes
- Opção –1 imprime tabela de variáveis locais
- Sem opções, mostra a interface da classe



2. Algoritmos de coleta de lixo

- Dados armazenados na pilha são automaticamente liberados, quando a pilha esvazia para ser reutilizada
- Mas dados armazenados no heap precisam ser reciclados através de liberação...
 - manual, em linguagens como C e C++ (freelists, delete, free)
 - automática, como em Java e maior parte das linguagens*
- Liberação automática de memória do heap é realizada através de algoritmos de coleta de lixo
 - Há várias estratégias, com vantagens e desvantagens de acordo com a taxa em que objetos são criados e descartados
 - Têm considerável impacto na performance (gerência explícita de memória também tem, e é muito mais complicada)



Coleta de lixo

- De acordo com a especificação da linguagem Java, uma JVM precisa incluir um algoritmo de coleta de lixo para reciclar memória não utilizada (objetos inalcançáveis)
 - A especificação não informa qual algoritmo deve ser usado apenas que deve existir um
 - A máquina virtual HotSpot, da Sun, usa vários algoritmos e permite diversos níveis de ajuste*
- O comportamento desse algoritmo é o principal gargalo na maior parte das aplicações de vida longa
 - Em média: 2% a 20% do tempo de execução de uma aplicação típica é gasto com coleta de lixo
 - Conhecer os detalhes do funcionamento do algoritmo de coleta de lixo é importante para saber como ajustá-lo para melhorar a eficiência de um sistema



Desafios da coleta de lixo

- Distinguir o que é lixo do que não é lixo
 - Algoritmos exatos garantem a identificação precisa de todos os ponteiros e a coleta de todo o lixo
 - Algoritmos conservadores faz suposições e pode deixar de coletar lixo que pode não ser lixo (possível memory leak)
 - Todos os coletores usados nas JVMs atuais são exatos
- Influência da coleta em alocações posteriores
 - A remoção de objetos deixa buracos no heap (fragmentação)
 - Para alocar novos objetos, é preciso procurar nas listas de espaços vazios (free lists) um que caiba o próximo objeto: alocação será mais demorada e uso do espaço é ineficiente.
 - Alguns algoritmos compactam o heap, movendo os objetos para o início do heap e atualizando os ponteiros: torna a alocação mais simples e eficiente, porém são mais complexos.



Algoritmos para coleta de lixo

Contagem de referências

- Reference counting algorithm: mantém, em cada objeto, uma contagem das referências para ele; coleta os objetos que têm contagem zero
- Cycle collecting algorithm: extensão do algoritmo de contagem de referência para coletar ciclos (referências circulares)

Rastreamento de memória

- Mark and sweep algorithm: rastreia objetos do heap, marca o que não é lixo e depois varre o lixo (libera memória)
- Mark and compact algorithm: extensão do algoritmo Mark and Sweep que mantém o heap desfragmentado
- Copying algorithm: divide o heap em duas partes; cria objetos em uma parte do heap e deixa outra parte vazia; recolhe o que não é lixo e copia para a área limpa, depois esvazia a área suja



Estratégias de coleta de lixo

- Algoritmos combinados
 - Estratégias usam ou baseiam-se em um ou mais dos algoritmos citados para obter melhores resultados em um dado cenário
- Classificação quanto à organização da memória
 - Generational (objetos transferidos para áreas de memória diferentes conforme sobrevivem a várias coletas de lixo)
 - Age-oriented (algoritmos diferentes conforme idade dos objetos)
- Classificação quanto ao nível de paralelismo
 - Serial
 - Incremental
 - Concorrente
- Principal argumento de escolha: eficiência vs. pausas



Metas ajustáveis

- Eficiência (throughput): tempo útil / tempo de faxina
 - Taxa entre o tempo em que uma aplicação passa fazendo sua função útil dividido pelo tempo que passa fazendo coleta de lixo
 - Ideal que seja a maior possível
- Pausas: quando o mundo pára (stop-the-world)
 - Tempo em que a aplicação inteira (todos os threads) da aplicação param para roda o GC e liberar memória
 - Ideal que seja o menor possível
- Como alcançar essas metas?
 - Escolhendo um coletor de lixo adequado (diferentes estratégias usam algoritmos diferentes, de formas diferentes)
 - Configurando parâmetros que modificam o espaço usado, influenciando a forma como o coletor gerencia memória



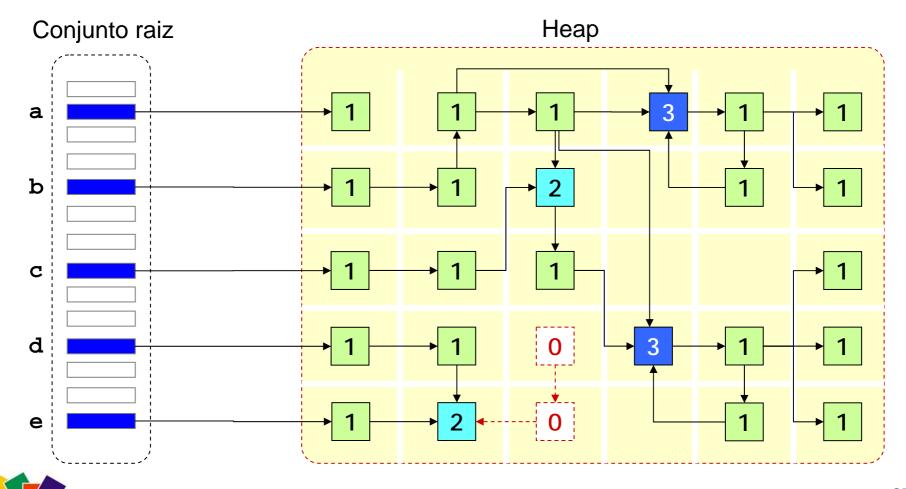
Contagem de referências (RC*)

- É o algoritmo mais simples [Collins 1960]
- Cada objeto possui um campo extra que conta quantas referências apontam para ele
 - Compilador precisa gerar código para atualizar esse campo sempre que uma referência for modificada
- Funcionamento:
 - Objeto criado em thread ativo: contagem = 1
 - Objeto ganha nova referência para ele (atribuição ou chamada de método com passagem de referência): contagem++
 - Uma das referências do objeto é perdida (saiu do escopo onde foi definida, ganhou novo valor por atribuição, foi atribuída a *null* ou objeto que a continha foi coletado): contagem--
 - Se contagem cair a zero, o objeto é considerado lixo e pode ser coletado a qualquer momento



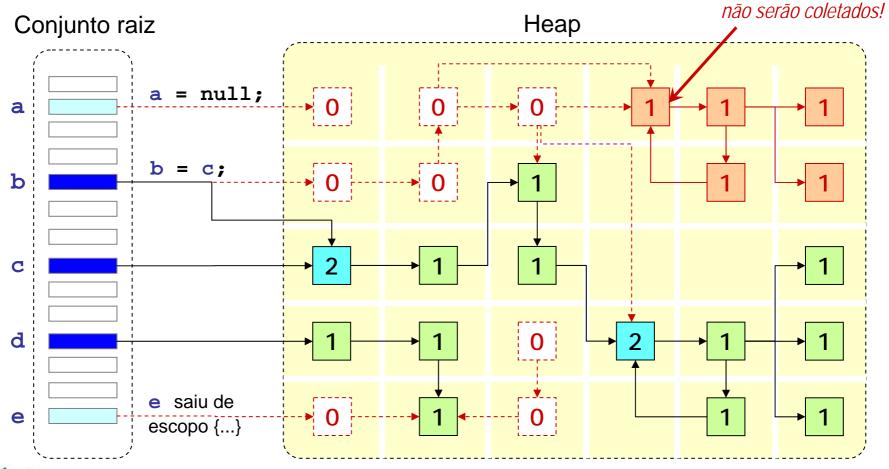
Contagem de referências (1)

 Cada seta que chega em um objeto é contada como uma referência para ele (independente de onde tenha vindo)



Contagem de referências (2)

 Referências circulares impedem que contagem caia para zero quando deveria.





Memory leak! Objetos

inalcançáveis que

RC: considerações

Vantagens

- Rápido: não precisa varrer o heap inteiro (só espaço ocupado)
- Pode executar em paralelo com a aplicação

Desvantagens do RC clássico

- Overhead alto
- Paralelismo caro
- Incapacidade de recuperar ciclos (objetos que mantém referências circulares entre si)

Soluções

- Coletores incrementais RC on-the-fly [Levanoni-Petrank 2001] reduzem overhead e custo do paralelismo, sem pausas
- Algoritmo eficiente de Coleta de Ciclos [Paz-Petrank 2003] ou backup com algoritmo de rastreamento (MS ou MC)



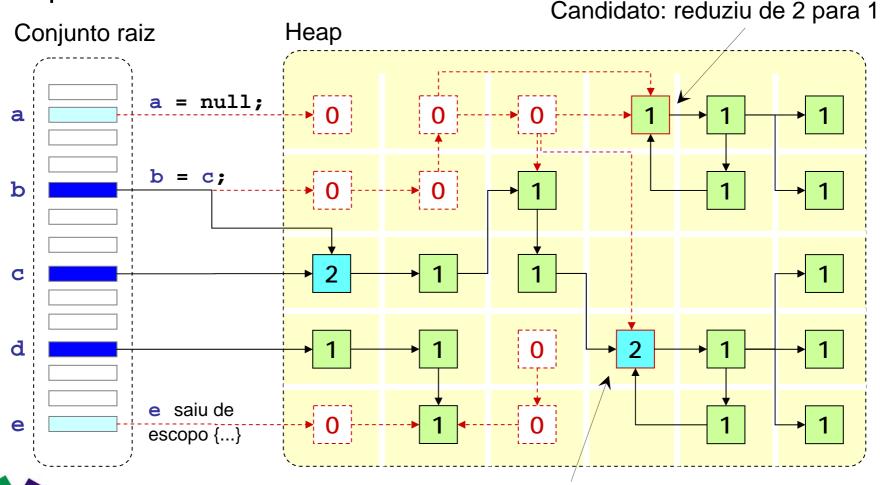
Coleta de ciclos (CC)

- Contagem de referências clássica não recolhe ciclos
- Coleção de ciclos baseia-se em duas observações
 - Obs1: Ciclos-lixo só podem ser criados quando uma contagem cai para valor diferente de zero
 - Obs2: Em ciclos-lixo, toda a contagem é devido a ponteiros internos
- Portanto, objetos que tem contagem decrementada para valores diferente de zero são candidatos (obs1)
- Algoritmo realiza três passos locais nos candidatos
 - 1. Mark: marca apenas objetos que têm ponteiros externos (obs2)
 - 2. Scan: varre o ciclo a partir do objeto candidato com ponteiro externo e restaura a marcação de objetos que forem alcançáveis
 - 3. Collect: coleta os nós cuja contagem for zero



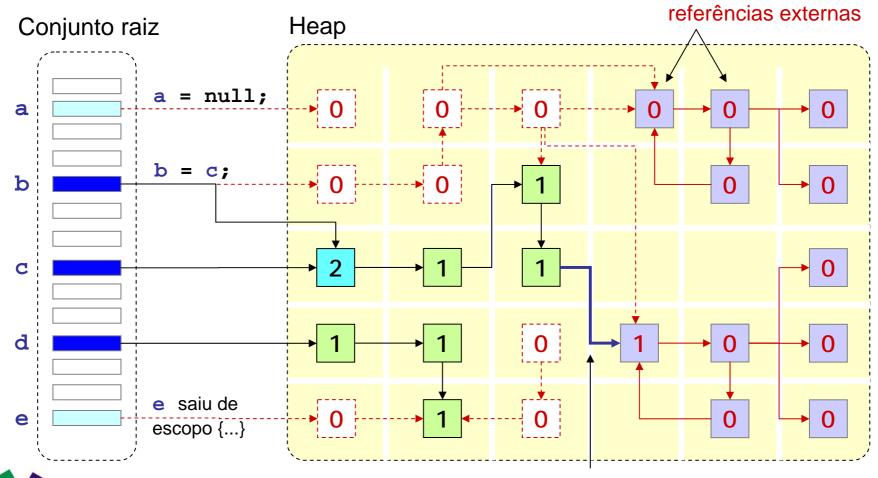
CC: identifica candidatos à remoção

 Candidatos: objetos cuja contagem foi decrementada para valor diferente de zero



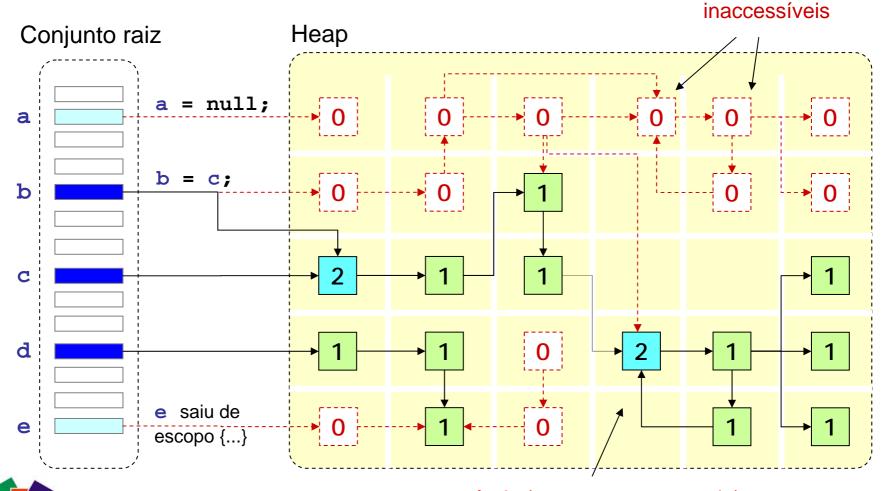
CC: passo 1 - mark

 Navega nas referências a partir do candidato e conta apenas as referências externas ao ciclo contagem de



CC: passo 2 - scan

 Restaura contagem dos nós que forem acessíveis através das referências externas



CC: considerações

Vantagens

- Trabalha com objetos ativos (não precisa pesquisar todo o heap)
- Pode trabalhar em paralelo com a aplicação (não pára tudo)

Desvantagens

- Ineficiente se houver muitos ciclos (precisa passar três vezes por cada um deles)
- Quando trabalha em paralelo, precisa garantir atomicidade das etapas de coleta de ciclos (complexo em multiprocessadores)

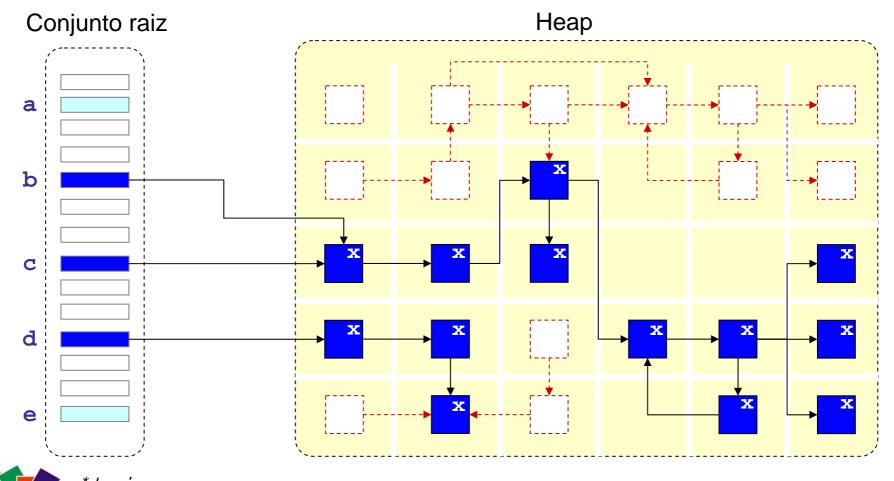
Soluções que usam CC

- "Efficient age-oriented concurrent cycle collector" [Paz et al. 2005]
- Uso experimental apenas (Jikes RVM)
 - A JVM HotSpot não tem, até o momento, empregado nenhum tipo de algoritmo de contagem de referências (até Java 5.0)



Algoritmos de rastreamento*

 Marcam as referências que são alcançáveis (navegando a partir do conjunto raiz), e remove todas as que sobrarem

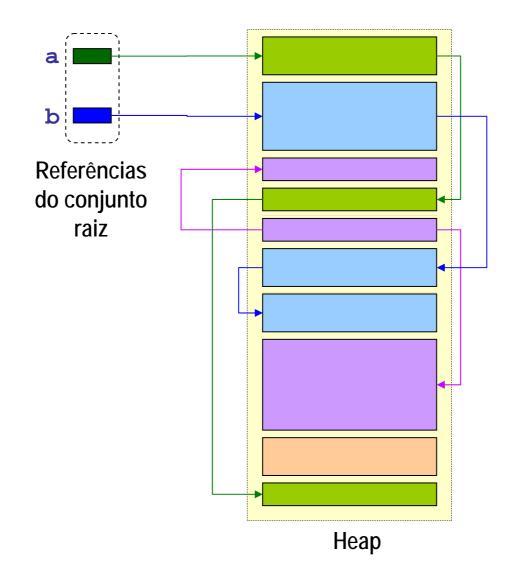


Algoritmo Mark and Sweep (MS)

- É o mais simples algoritmo de rastreamento (tracing)
- É executado quando a memória do heap atinge um nível crítico (ou acaba)
- Todos os threads da aplicação param para executá-lo
 - Comportamento chamado de "Stop-the-World"
- Originalmente projetado para a linguagem LISP pelo seu criador [McCarthy 1960]
- Duas fases
 - Mark: navega pelos objetos alcançáveis a partir do conjunto raiz e deixa uma marca neles
 - Sweep: varre o heap inteiro para remover os objetos que não estiverem marcados (lixo), liberando a memória

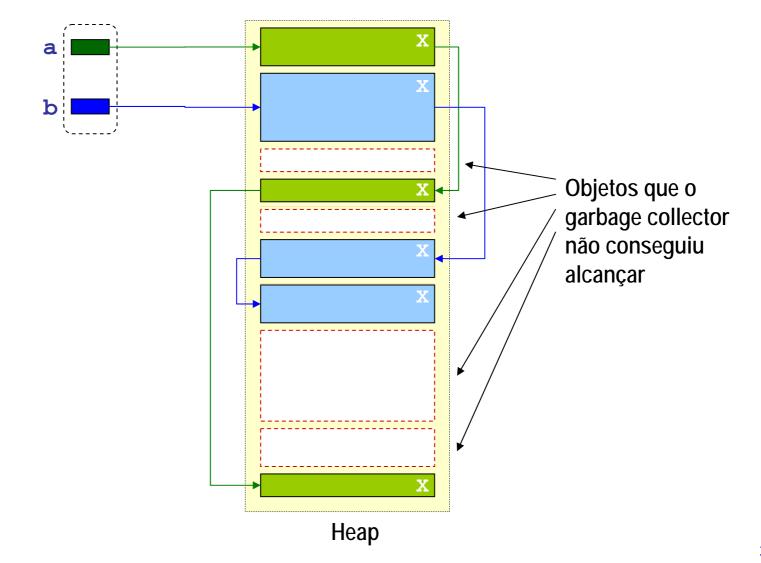


MS: o heap antes da coleta



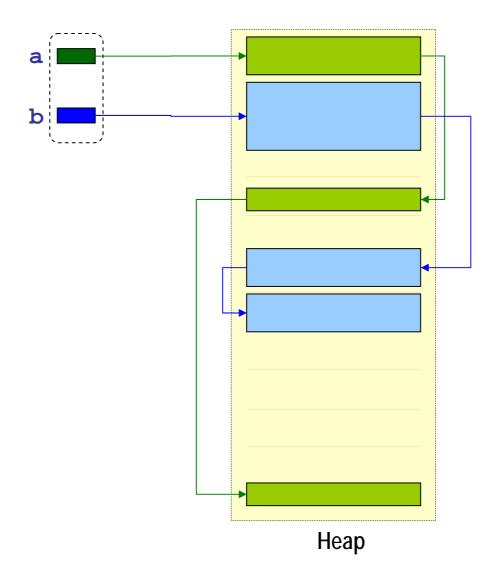


MS: fase de marcação: Mark





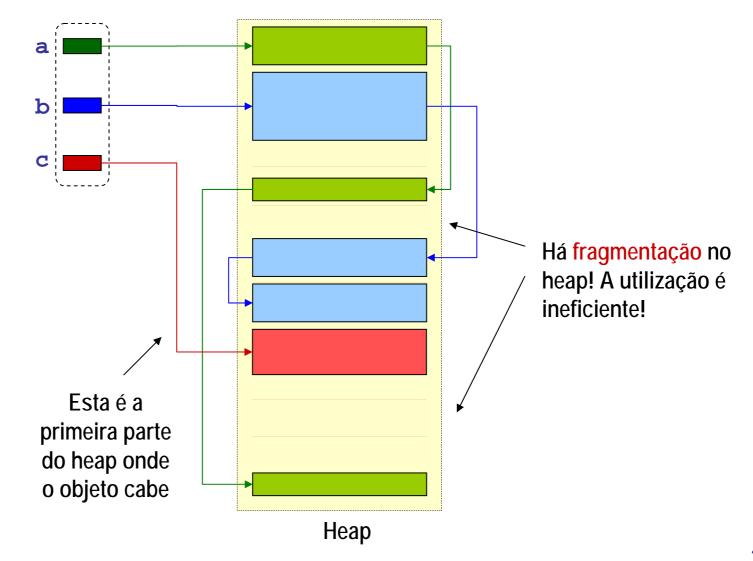
MS: fase da faxina: Sweep



Objetos que não foram marcados foram varridos do heap!



MS: alocação de novos objetos





MS: considerações

Vantagens

- Não precisa de algoritmo complicado para remover objetos com referências circulares
- Pode ser mais rápido que contagem de referências se heap não for excessivamente grande e objetos morrerem com frequência

Desvantagens

- Interrompe a aplicação principal (provoca pausa)
- Fragmentação pode aumentar a frequência em que o CG ocorre, com o tempo
- Precisa visitar todos os objetos alcançáveis na fase de marcação e varrer o heap inteiro para localizar objetos não marcados e liberar a memória



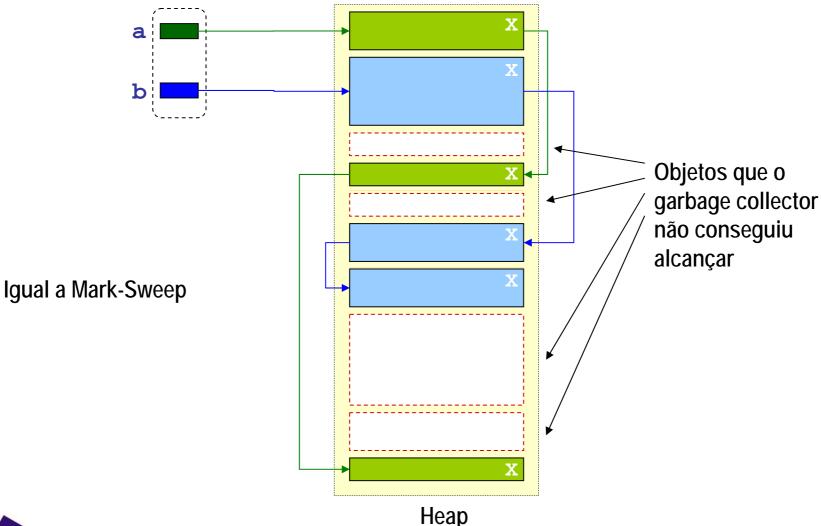
Algoritmo Mark-Compact (MC)

[Edwards]

- Algoritmo de rastreamento baseado no algorítmo mark-sweep (MS)
 - Acrescenta um algorítmo de compactação que não provoca fragmentação de memória
- Duas fases
 - Mark: idêntica ao mark-sweep
 - Compact: objetos alcançáveis são movidos para frente até que a memória que ocupa seja contígua
- Também é "Stop-the-World"
 - Precisa interromper a aplicação para rodar

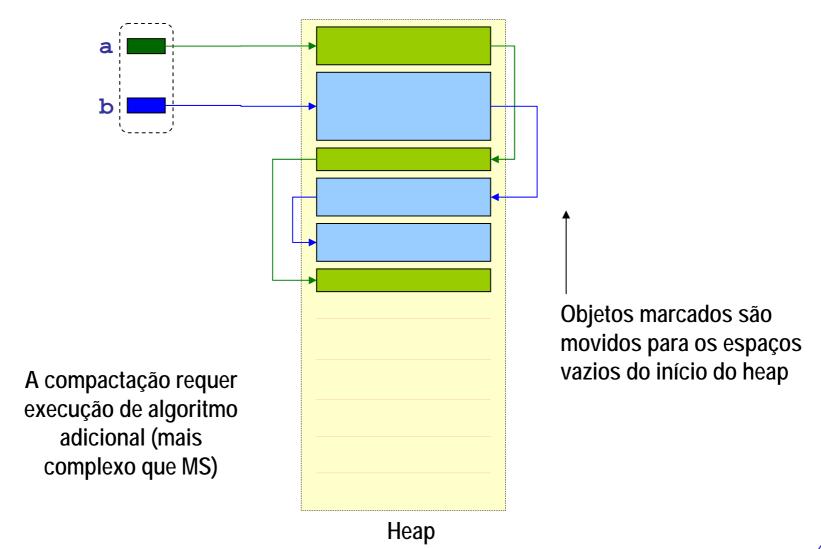


MS: fase de marcação: Mark



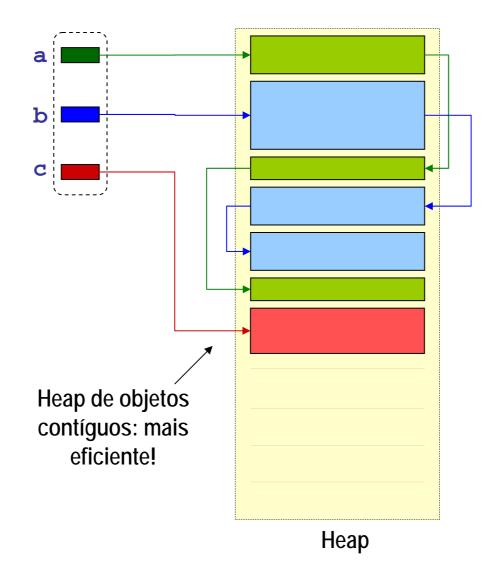


MC: fase de compactação: Compact





MC: alocação de novos objetos





MC: considerações

Vantagens

 Não causa fragmentação da memória: alocação é rápida e performance não se degrada com o tempo devido ao aumento das coletas

Desvantagens

- Continua sendo Stop-the-World e pausas tendem a ser maiores que as pausas em MS
- O algoritmo de compactação tem overhead (requer várias visitas) e é mais complicado de implementar em CGs concorrentes (multiprocessadores)
- Veja exemplo gráfico interativo de algoritmo Mark-Sweep-Compact (applet Java "Heap of Fish")
 - http://www.artima.com/insidejvm/applets/HeapOfFish.html (Bill Venners, do livro "Inside the Virtual Machine") [Venners]

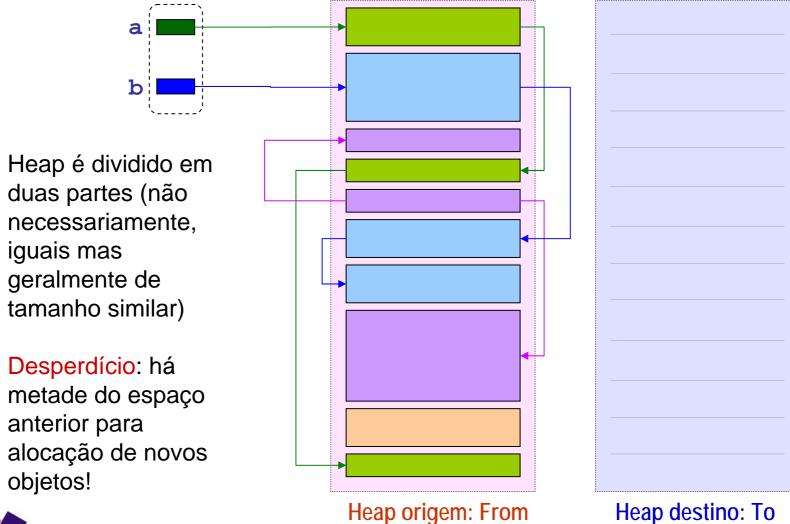


Algoritmo de cópia: CA

- Copying algorithm [Chenney 1970]
- Divide o heap em duas áreas iguais chamadas de origem (from space) e destino (to space)
- Funcionamento
 - 1. Objetos são alocados na área "from"
 - 2. Quando o coletor de lixo é executado, ele navega pela corrente de referências e copia os objetos alcançáveis para a área "to"
 - 3. Quando a cópia é completada, os espaços "to" e "from" trocam de papel

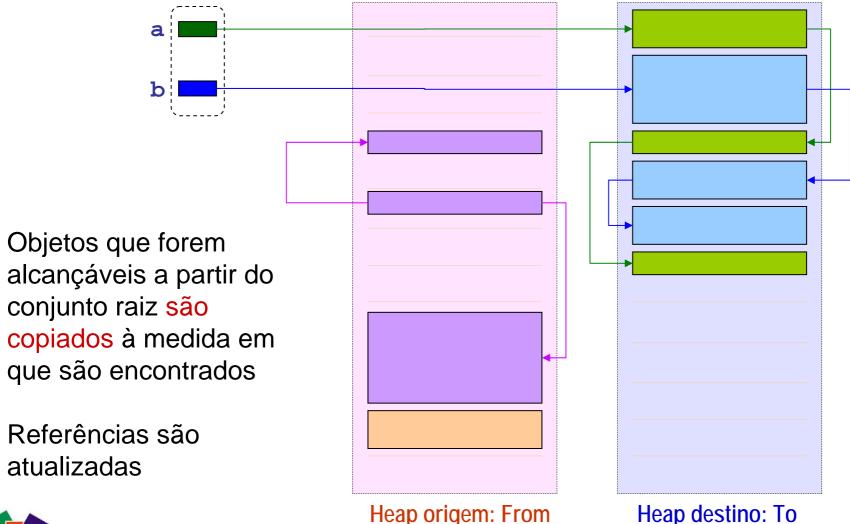


CA: antes da coleta



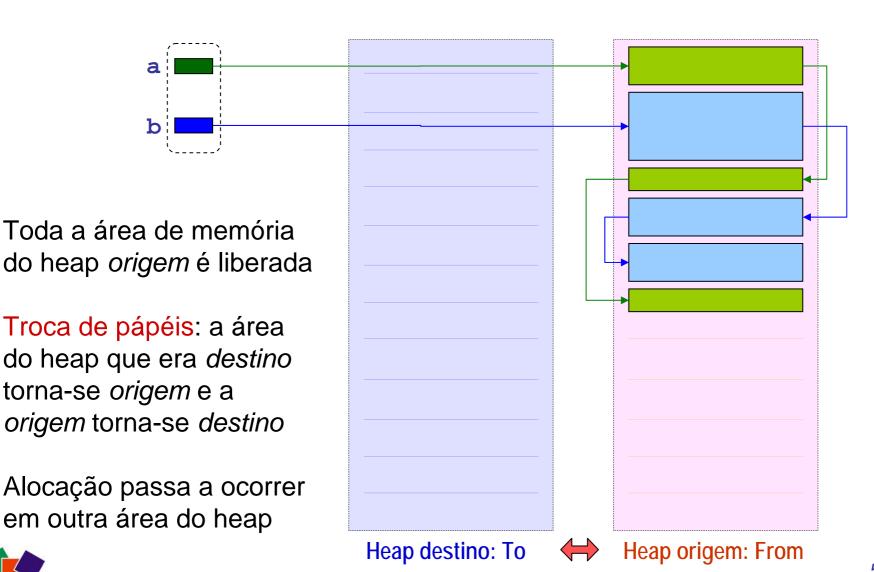


CA: copia objetos alcançáveis



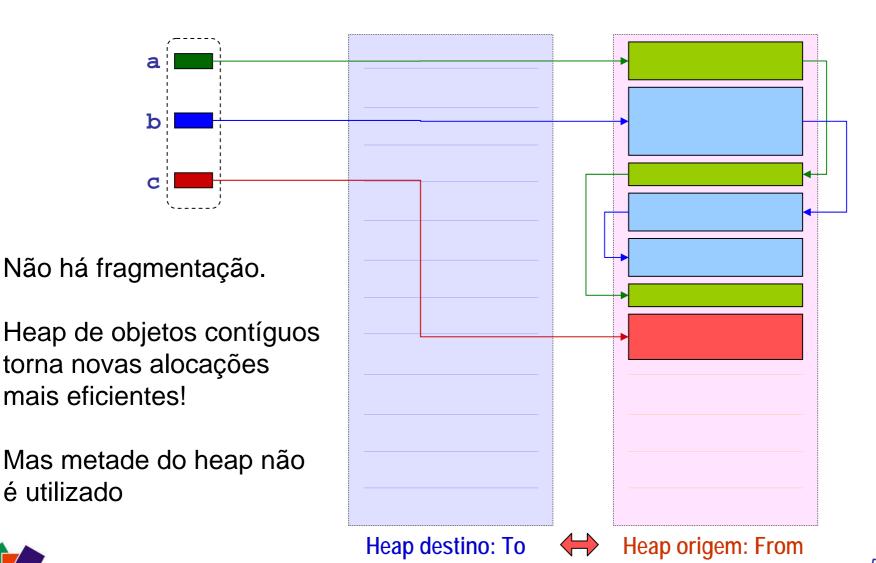


CA: esvazia e troca de papel





AC: alocação de novos objetos





AC: considerações

Vantagens

- Cópia é rápida, principalmente se a quantidade de objetos alcançáveis for pequena (o que é comum)
- Não precisa visitar o heap inteiro: apenas objetos alcançáveis
- Não fragmenta a memória do heap

Desvantagens

- Aplicação precisa parar (stop-the-world) enquanto o algoritmo está sendo executado (como em qualquer algoritmo de rastreamento); versão concorrente [Baker] tem menos pausas
- Dobra a necessidade de memória do heap: um problema se o heap necessário for muito grande; heaps menores (com metade do tamanho normal) podem disparar o GC com mais freqüência, reduzindo o throughput
- Uso ineficiente de memória (metade está sempre vazia)



Comparação (em coletor serial)

Em vermelho, geralmente um critério negativo precisa varrer heap inteiro Precisa parar a apicação pernite uso total do head coleta todo o lixo tradmenta o heap

JSado no Hot Spot Julit*

Contagem de referências	não	não	não	sim	sim	não	
Coleção de ciclos	não	sim	não	sim	sim	não	
Mark-sweep	sim	sim	sim	sim	sim	sim	
Mark-compact	sim	sim	sim	não	sim	sim	
Copying	não	sim	sim	não	não	sim	



não funciona de forma incremental (stop-the-world)

3. Estratégias de coleta de lixo

- Coletores modernos combinam vários algoritmos em estratégias mais complexas
 - Aplicando algoritmos diferentes conforme as idades e localização dos objetos
 - Utilizando técnicas que possibilitem a coleta de lixo paralela (algoritmos incrementais e concorrentes)
- Nesta seção apresentaremos as principais estratégias usadas (e propostas) para coletores seriais e paralelos
 - Generational garbage collection (usada na JVM HotSpot)
 - Age-oriented garbage collection (em fase experimental)
- Ambas baseiam-se na idade dos objetos para tornar as coletas mais eficientes



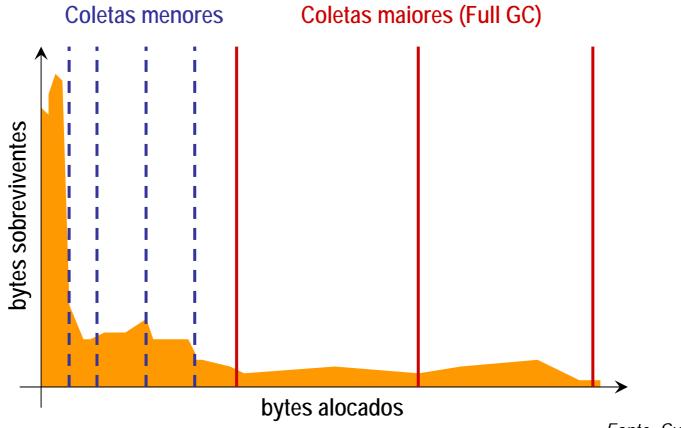
Vida dos objetos

- Observações empíricas
 - 1. Se um objeto tem sido alcançável por um longo período, é provável que continue assim
 - 2. Em linguagens funcionais, a maior parte dos objetos morre pouco depois de criados
 - 3. Referências de objetos velhos para objetos novos são incomuns
- Conclusão
 - Pode-se tornar mais eficiente o coletor de lixo se analisando os objetos jovens com mais freqüência que os objetos mais velhos



Mortalidade infantil dos objetos

- Objetos morrem jovens!
 - A maior parte, pouco depois de serem alocados





Generational GC

[Lieberman-Hewitt 83] e [Ungar 84]

- Classifica objetos em diferentes gerações: G₀, G₁, ...
 - G₀ contém objetos jovens recém-criados
 - Pressupõe-se que a maior parte dos objetos jovens (90%) é lixo antes da próxima coleta
 - $-G_n$ é varrida mais frequentemente que G_{n+1}
 - Objetos sobreviventes são promovidos para a geração seguinte
- As gerações mais velhas devem ser maiores que as gerações mais novas
 - Tipicamente são exponencialmente maiores
- Implementações típicas usam apenas duas gerações
 - Geração jovem (G₀)
 - Geração estável (G₁)



Fundamentos do Generational GC

- Duas hipóteses
 - Mortalidade infantil dos objetos: a maior parte dos objetos (95%) morre pouco depois que são criados
 - Haverá poucas referências de objetos mais velhos para objetos mais jovens
- As gerações são áreas do heap
 - Geração jovem: área menor, onde é inicialmente alocada a memória para novos objetos
 - Geração antiga, ou estável: área maior, para onde são copiados objetos que sobrevivem a uma ou mais coletas de lixo na área menor



Ponteiros entre gerações

- Quando um objeto é criado, suas referências geralmente apontarão para objetos mais antigos
 - Se houver ponteiros entre gerações, provavelmente serão da geração nova para a geração velha
- Pode acontecer de um objeto antigo receber referência para um objeto novo algum tempo depois de criado
 - Neste caso o sistema precisa interceptar modificações em objetos antigos e manter uma lista de referências
 - Isto deve ocorrer raramente (se ocorrer com frequência, as coletas menores serão demoradas)
- Na HotSpot JVM, é usada uma tabela de referências
 - Geração antiga é dividida em blocos de 512kb (cards)
 - Alterações são interceptadas e blocos são marcados
 - Coletas menores verificam apenas blocos marcados



Generational GC: algorítmos

- Usa mais de um algorítmo, uma vez que cada geração possui tamanhos e comportamentos diferentes
- Geração jovem
 - 90% dos objetos estão mortos
 - Área total do heap usado é pequeno
 - Algoritmo de cópia é a melhor opção pois seu custo é proporcional aos objetos ativos
- Geração estável
 - Pode haver muitos objetos ativos e área é grande
 - Não há unanimidade quanto ao algoritmo
 - Pesquisas recentes exploram o uso de algoritmos de contagem de referência (CC) com coletas frequentes e incrementais
 - HotSpot usa MS (na versão concorrente) e MC

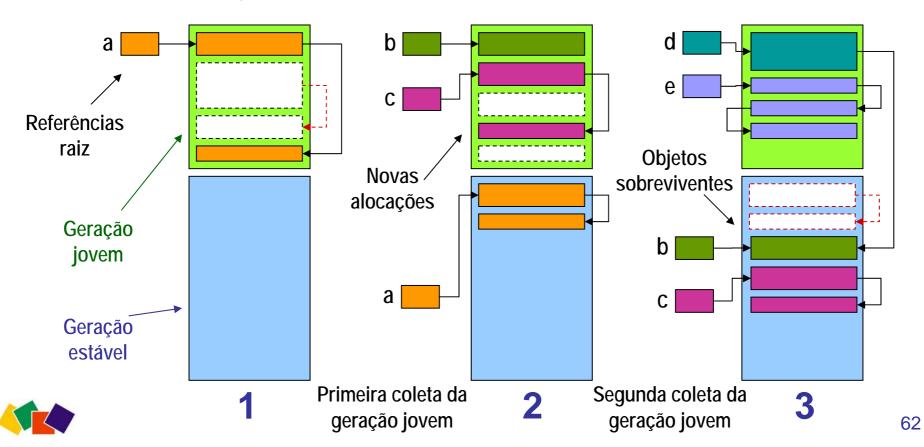


Funcionamento: generational GC

- Ilustrando caso típico (há muitas variações)
 - Duas gerações (G₀: jovem e G₁: estável)
 - Algoritmo de cópia usado na geração jovem
- Quando cada geração enche, ocorrem coletas de lixo
 - Parciais na geração jovem, e completas no heap inteiro
- GC Parcial: A geração jovem enche primeiro, já que acumula objetos mais rapidamente
 - Quando a geração jovem enche, causa uma coleta menor, que é rápida (proporcional ao número de objetos ativos)
 - Sobreviventes da coleta serão copiados para a geração antiga
- GC Completa: A geração antiga cresce ao receber os sobreviventes da geração jovem. Vários irão morrer.
 - Depois de várias coletas menores, a geração antiga enche
 - Quando encher, haverá uma coleta maior (lenta) no heap inteiro

Funcionamento ilustrado

- Geração jovem recebe novas alocações até encher
- Quando a geração jovem enche ocorre a coleta que copia os objetos sobreviventes para a geração estável
- Coleta na geração estável é mais demorada, porém menos frequente



Considerações

Vantagens

- Pausas menores: coletas rápidas e freqüentes distribuem as pausas que podem tornar-se imperceptíveis
- Eficiência (throughput): a coleta concentra-se nas áreas de memória onde o lixo se encontra, gastando menos tempo

Desvantagens

- Pequena geração jovem pode causar início mais lento devido a muitas coletas curtas (baixa eficiência)
- Coleta na geração antiga ainda é lenta e algoritmos usados atualmente ainda não conseguem eliminar pausas

Implementações

- Na JVM HotSpot, geração antiga usa diversos algorítmos (MC, MS)
- Há pesquisas usando RC (CC) para coletar geração antiga eficientemente: [Azatchi-Petrank 03] e [Blackburn-Mckinley 03] com implementações experimentais testadas no Jikes RVM



Age-oriented

[Paz, Petrank & Blackburn 2005]

- Divide objetos em gerações
 - Ocupam tamanho variável do heap
 - Sempre coleta heap inteiro
- Busca reduzir pausas com concorrência
- Implementação recomendada usa
 - Algoritmo de rastreamento (cópia) na geração jovem (da mesma forma que implementações típicas do Generational GC)
 - Algoritmo de contagem de referências (CC) na geração antiga
- Inicialmente geração jovem ocupa todo o espaço
 - Alta eficiência (demora ocorrência de primeira coleta)
- Geração antiga cresce com coletas
 - Pequena geração antiga com mais objetos ativos que mortos e pouca atividade permite eficiência máxima do algoritmo CC



Generational vs. Age-oriented

Generational

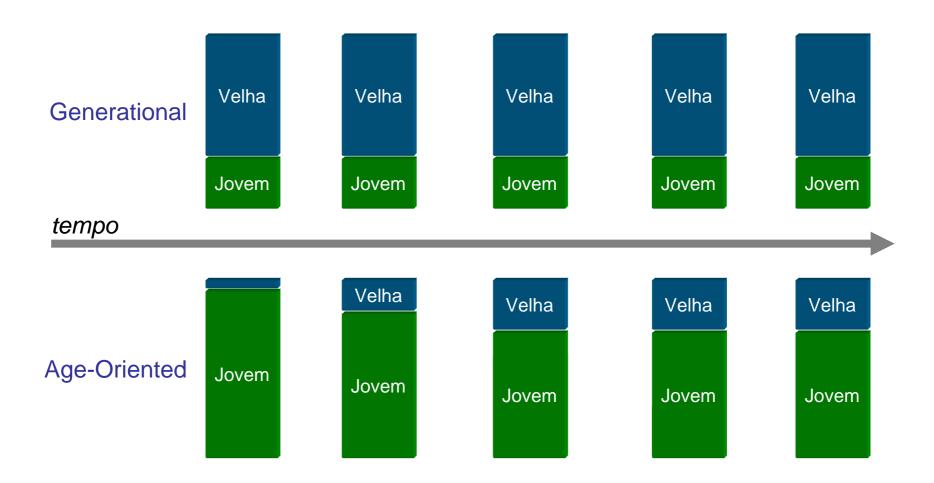
- Geração jovem menor que geração velha
- Faz coletas freqüentes apenas na geração jovem
- Faz coleta do heap inteiro, com algoritmo diferente, após várias coletas da geração jovem

Age-oriented

- Geração jovem maior que geração velha
- Sempre coleta o heap inteiro, usando algoritmos diferentes para cada geração



Generational vs. Age-oriented





Considerações

Vantagens

- Maior geração jovem possível (coletas raras e menos pausas)
- Cada geração tratada diferentemente (eficiência)

Desvantagens

- Pausas serão longas na geração jovem se não for usado um coletor concorrente (usando algoritmo de cópia concorrente)
- Coleta na geração antiga será ineficiente se for usado algoritmo de rastreamento (ideal é usar contagem de referências)

Suporte

- Experimental (objeto de pesquisa atual)
- Não é suportado por nenhuma JVM HotSpot no momento
- Implementação em Jikes RVM obteve performance melhor que implementação HotSpot



4. Coleta de lixo em paralelo

- Há três* estratégias de coleta de lixo quanto à execução paralela do coletor de lixo
 - Coleta serial: o coletor ocorre em série com a aplicação, parando o mundo (stop-the-world) quando precisar liberar memória
 - Coleta incremental (on-the-fly): o coletor executa em paralelo realizando coletas pequenas (não necessariamente completas) sempre que possível, usando vários threads visando menos (ou zero) pausas
 - Coleta concorrente: o coletor realiza suas principais tarefas em um processador ou thread exclusivo (pode parar todos os threads para marcar, se necessário) visando maior eficiência



Parando o mundo

- Os algoritmos seriais de rastreamento precisam parar todos os threads para realizar coleta de memória
 - Rastreamento: qualquer estratégia que use MC, MS ou CA
- Por que é preciso parar o mundo?
 - Enquanto o thread de rastreamento varre o heap à procura de objetos alcançáveis, alguns dos já marcados poderiam tornar-se inalcançáveis se o programa principal não fosse interrompido
- Por que n\u00e3o usar os algoritmos de contagem de referência (RC e CC)?
 - É uma solução. Podem operar em paralelo sem parar tudo
 - Ainda estão pouco maduros (são foco atual de pesquisas)
 - Atualmente são usados apenas experimentalmente; é possível que venham a ser usados no futuro nas JVMs HotSpot



Rastreamento incremental

- Os algoritmos de rastreamento mostrados não podem ser usados em sistemas de tempo real pois introduzem a qualquer momento pausas de duração imprevisível
 - Sistemas de tempo real requerem tempos de resposta previsíveis e determinísticos
- Para usar coleta de lixo em sistemas de tempo real é preciso eliminar totalmente as pausas!
- Solução: buscar algoritmos capazes de executar em paralelo e não interferir na execução da aplicação
 - Soluções baseadas em contagem de referências RC/CC
 - Versões incrementais de algoritmos de cópia e MS/MC
 - Rastreamento baseado em marcação tricolor (TCM)



Marcação tricolor (TCM)

[Dijkstra 76]

- Um algoritmo de rastreamento que atribui um entre três estados (cores) a um nó do grafo de objetos
 - Principal algoritmo de coleta de lixo incremental
- Cores e tipos de nó
 - Branco: nó e seus filhos (objetos ao qual se refere) ainda não alcançados (não foram marcados)
 - Cinza: nó já foi alcançado (e marcado), mas seus filhos ainda não foram
 - Preto: nó e seus filhos já foram alcançados e marcados
- No final da fase de marcação do algoritmo, os nós que ainda estão marcados com a cor branca podem ser coletados com segurança



TCM: funcionamento

1. Inicialização

- Inicialmente todos os nós são brancos (inalcançáveis)
- O conjunto de referências raiz é marcada cinza

2. Rastreamento e marcação 1 (cinza):

- Quando o coletor encontra um caminho entre um nó cinza e um nó branco, pinta o nó branco de cinza
- Prossegue recursivamente até encontrar todos os objetos alcançáveis a partir dele, pintando cada um de cinza

3. Rastreamento e marcação 2 (preto):

 Quando todos os caminhos de um nó cinza levam a nós cinza ou pretos, o nó é pintado de preto

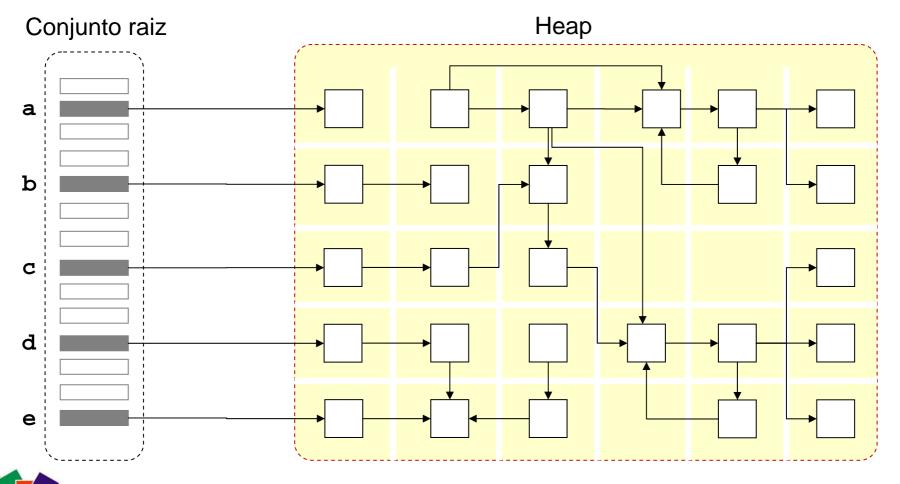
4. Reciclagem e liberação de memória:

 Quando não houver mais nós cinzas, todos os nós alcançáveis foram encontrados. Os nós brancos restantes são reciclados.

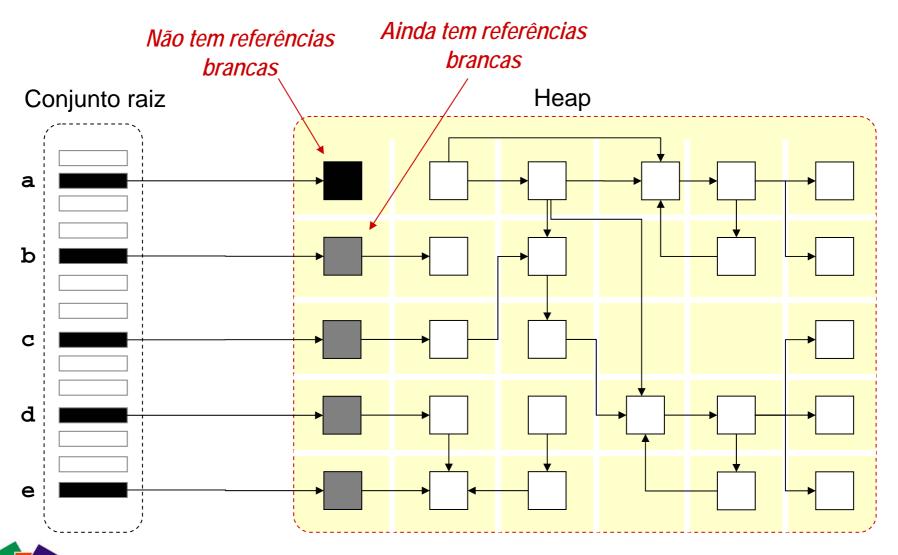


TCM (1): inicialização

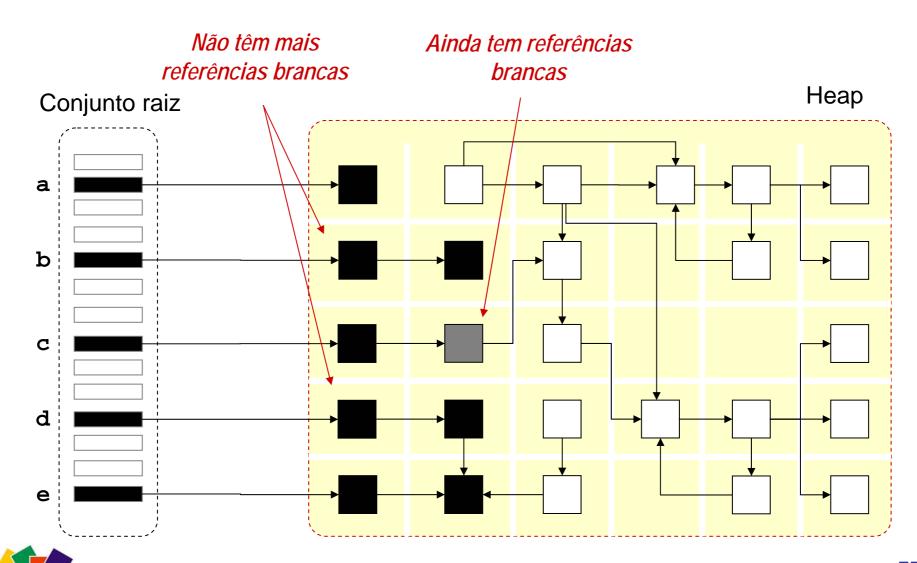
- Todos os nós inicialmente marcados como brancos
- referências raiz em cinza



TCM (2): marcação cinza

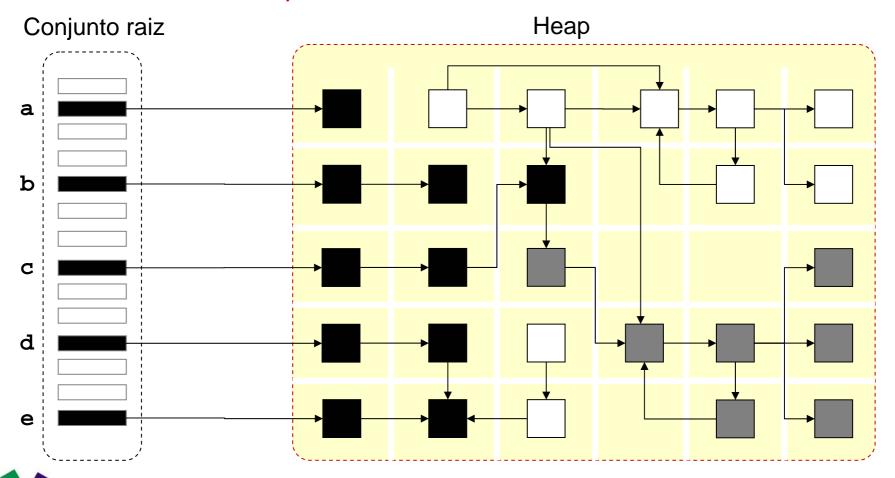


TCM (3): marcação preta



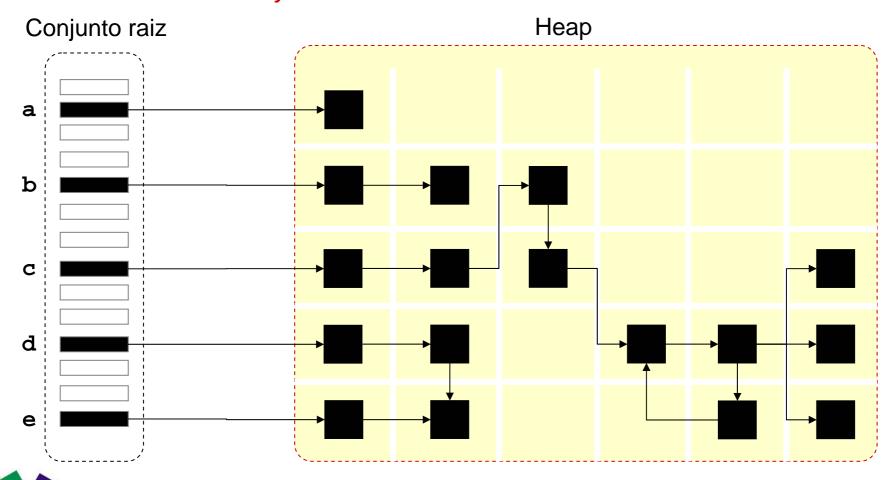
TCM (4): marcações recursivas

Brancos que sobraram serão coletados pois são inaccessíveis



TCM (5): reciclagem dos brancos

Heap final contém apenas objetos ativos





Invariante tricolor

- Um objeto preto nunca poderá ter referências para objetos brancos
 - Quando aplicação gravar uma referência entre um nó preto e um branco, o coletor precisará pintar ou o nó pai ou o nó filho de cinza
 - Quando a aplicação quiser ler um nó branco, ele tem que ser pintado de cinza
- Para realizar isto, o sistema precisa
 - Rastrear gravações em nós pretos (usando uma barreira de gravação – write barrier)
 - Rastrear leituras em nós brancos (usando uma barreira de leitura – read barrier)



TCM: considerações

Vantagens

- Possibilidade de uso incremental e eliminação de pausas na coleta de lixo (permite uso em aplicações de tempo real)
- Melhor performance aparente

Desvantagens

- Sincronização é complexa entre a aplicação e o coletor de lixo
- Barreiras podem dificultar a implementação em diferentes sistemas e diminuir a eficiência (menos throughput)

Suporte em JVMs

 Atualmente, em máquinas virtuais Java é usado apenas experimentalmente (HotSpot JVM não usa este algoritmo; usa versões incrementais de outros algoritmos de rastreamento)



Train algorithm

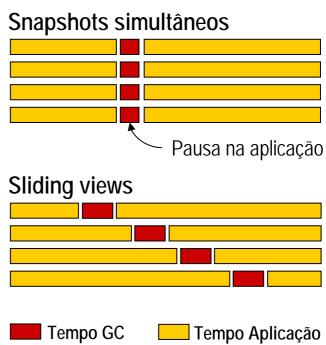
[Hudson & Moss 92]

- Algoritmo incremental usado para coleta de geração estável em sistemas que usam Generational GC
- Divide a memória em blocos de tamanho fixo
 - Metáfora: blocos menores são "vagões" e coleções de tamanho arbitrário desses blocos são "trens"
 - Trens e vagões são ordenados por idade; os mais antigos são coletados enquanto novos trens e vagões se formam
 - Entre a formação e coleta, atualiza-se referências entre objetos
 - Muito ineficiente com objetos populares (objetos que têm muitas referências) que podem ocorrer com freqüência nas gerações estáveis; versões eficientes podem ter pausas pequenas
- O Train algorithm é usado na JVM HotSpot
 - Mas parou de ser mantido a partir da versão 1.4.2



Snapshots e Sliding Views

- Coletores paralelos precisam trabalhar com heaps que mudam durante a coleta
 - Enquanto um thread marca os objetos outro thread pode estar liberando referências (gerando lixo)
 - É preciso trabalhar com modelos estáticos do heap (snapshots ou sliding views) e coletar de forma incremental
- Snapshots (concurrent GC)
 - Precisa parar todos os threads para obter um modelo do heap em determinado momento
- Sliding views (on-the-fly GC)
 - Pára um thread de cada vez, em tempos desencontrados para obter a visão do heap (sem pausa na aplicação)





On-the-fly GC (incremental)

- Área de pesquisa emergente
 - Contagem de referência (CC) torna-se mais popular com heaps grandes (já que pesquisa objetos vivos) e sistemas paralelos (onde suas desvantagens diminuem)
- Vários artigos recentes
 - RC (CC) on-the-fly com sliding views [Levanoni-Petrank 01]
 - Mark Sweep on-the-fly com sliding views [Azatchi-Levanoni 03]
 - On-the-fly cycle collection [Paz et al 2003]
 - On-the-fly generational collector [Domani et al 2000]
- Implementações
 - Todas experimentais (Jikes RVM)
 - Podem aparecer em versões futuras de VMs comerciais de Java (e também de C#)



Concurrent GC (rastreamento)

- Algoritmo de cópia concorrente
 - Cópia incremental ([Baker 78]): ponteiros são lidos apenas em to_space; se ponteiro estiver em from_space na leitura, primeiro copia objeto depois obtém ponteiro
 - Algoritmo similar é usado pela HotSpot JVM para coletar paralelamente a geração jovem (mais sobre isto na seção seguinte). Veja [Flood et al 2001].
- Mark-sweep concorrente
 - Usado pelo HotSpot JVM para coletar paralelamente a geração antiga (mais na seção seguinte) [Printezis 00]
 - Causa fragmentação (não compacta)
 - Causa pausa pequena para obter snapshot (pára todos os threads ao mesmo tempo)
 - Versão com compactação em desenvolvimento [Flood et al 01]



Conclusões

- Existem muitas estratégias de coleta de lixo
 - Há muito, muito mais do que foi exposto aqui
- Embora o programador Java não tenha a opção de escolher qual usar, as JVMs podem permitir essa escolha e configuração
- Muito pode mudar nas próximas versões das JVMs existentes atualmente
 - Há muitas estratégias experimentais que poderão ser usadas em versões futuras, em diferentes plataformas
 - Há estratégias antigas caindo em desuso
- Conhecer o funcionamento dos principais algoritmos ajudará a configurar e ajustar a performance da JVM em diferentes tipos de aplicações



Referências: algoritmos (artigos, 1)

- [Collins 60] G. Collins. A Method for Overlapping and Erasure of Lists, IBM, CACM, 1960. Algoritmo de contagem de referências.
- [McCarthy 60] J. McCarthy. Recursive Functions of Symbolic Expressions and Their Computation by Machine, Part I, MIT, CACM, 1960. Artigo original do Mark-Sweep algorithm (em Lisp).
- [Edwards] D.J. Edwards. Lisp II Garbage Collector. MIT. AI Memo 19. ftp://publications.ai.mit.edu/ai-publications/0-499/AIM-019.ps. *Mark-Compact.*
- [Cheney 70] C. J. Cheney. A Nonrecursive List Compacting Algorithm. CACM, Nov 1970. Artigo original do copying algorithm.
- [Baker 78] H. G. Baker. List processing in real time on a serial computer. CACM, Apr 1978. Uma versão concorrente do copying algorithm.
- [Lieberman-Hewitt 83] H. Lieberman, C. Hewitt. A Real Time Garbage Collector Based on the Lifetimes of Objects. CACM, June 1983. *Artigo principal do Generational GC.*
- [Dijkstra 76] E. W. Dijkstra, L. Lamport, et al. On-the-fly Garbage Collection: An Exercise in Cooperation. Lecture Notes in Computer Science, Vol. 46. 1976. *Tri-color marking (citado em [Jones & Lins 95]).*
- [Ungar 84] David Ungar. Generation Scavenging: A Non-disruptive High Performance Storage Reclamation Algorithm. ACM, 1984. *Um dos artigos do Generational GC.*



Referências: algoritmos (artigos, 2)

- [Hudson & Moss 92] R. Hudson, J.E.B. Moss. Incremental Collection of Mature Objects, ACM/IWMM, Sep 1992. *Artigo do Train algorithm.*
- [Domani 00] T. Domani et. al. A Generational On-The-Fly Garbage Collector for Java, IBM, 2000.
- [Printezis 00] Tony Printezis and David Detlefs. A Generational Mostly-concurrent Garbage Collector, 2000. *Algoritmo usado no HotSpot.*
- [Flood et al 02] Christine Flood et al. Parallel Garbage Collection for Shared Memory Multiprocessors. Sun Microsystems. Usenix, 2001. *Algoritmos usados no HotSpot.*
- [Bacon-Rajan 01] D. Bacon, V. T. Rajan. Concurrent Cycle Collection in Reference Counted Systems. IBM, 2001.
- [Levanoni-Petrank 01] Y. Levanoni, E. Petrank. An On-the-fly Reference Counting Garbage Collector for Java, IBM, 2001.
- [Azatchi 03] H. Azatchi et al. An On-the-Fly Mark and Sweep Garbage Collector Based on Sliding Views. OOPSLA 03, ACM, 2003.
- [Paz 05] H. Paz et al. Efficient On-the-Fly Cycle Collection. IBM (Haifa), 2005.
- [Paz-Petrank-Blackburn 05] H. Paz, E. Petrank, S. Blackburn. Age-Oriented Concurrent Garbage Collection, 2005.



Referências: outros tópicos

Gerência de memória

[Memory] The Memory Management Reference. http://www.memorymanagement.org/. Várias referências e textos sobre gerêncie de memória em geral.

Máquina virtual da Sun

[JVMS] T. Lindholm, F. Yellin. The Java Virtual Machine Specification, second edition, Sun Microsystems, 1999. Formato de memória, pilha, heap, registradores na JVM.

[Sun 05] Sun Microsystems. Tuning Garbage Collection with the 5.0 Java[tm] Virtual Machine. 2005. Generational GC e estratégias paralelas no HotSpot.

[HotSpot] Sun Microsystems. The Java HotSpot™ Virtual Machine, v1.4.1, Technical White Paper. Sept. 2002. *Algoritmos usados no HotSpot.*

[Printezis 05] Tony Printezis. Garbage Collection in the Java HotSpot Virtual Machine. http://www.devx.com/Java/Article/21977, DevX, 2005.

Livros

[Jones & Lins 96] R. Jones, R.Lins. Garbage Collection: Algorithms for Automatic Dynamic Memory Management. Wiley 1996. Várias estratégias de GC explicadas.

Simulações

[Venners] Bill Venners, Inside the Virtual Machine. Applet Heap of Fish: http://www.artima.com/insidejvm/applets/HeapOfFish.html



© 2005, Helder da Rocha www.argonavis.com.br